TECH CHALLENGE FASE 2

Otimização de rotas médicas com algoritmo genético e LLM

Múltiplos veículos, prioridades e interpretação de soluções verificadas

Equipe

Lucas dos Santos Batista RM 376835

Eduardo Fagner Costalonga Ribeiro RM 376780

Renan Gonçalves Micheletti RM 376743

Outubro de 2026

Relatório técnico da entrega local

1 Visão geral e escopo

Implementamos um sistema de planejamento da distribuição de medicamentos e insumos por múltiplos veículos, com capacidade, autonomia e prioridades. O núcleo utiliza um algoritmo genético, comparado com uma heurística gulosa e OR-Tools. Uma camada de linguagem organiza fatos de soluções verificadas para produzir instruções, relatórios e respostas a perguntas.

A avaliação mostra que o genético encontra rotas viáveis e melhora alguns casos menores, mas não supera OR-Tools nos benchmarks maiores. A reparação consome uma parte relevante do orçamento, limitando a evolução. Esse resultado orienta a discussão das limitações e evita atribuir à abordagem ganhos que não foram observados.

O cenário hospitalar é fictício e utiliza ruas reais da região central de São Paulo. Os tempos são estimativas sem trânsito em tempo real. Não usamos pacientes, medicamentos reais, estoques ou desfechos clínicos. Os pesos de prioridade representam premissas do experimento.

Componente	Entrega
Otimização	Pacote Python compartilhado por CLI, notebooks e API
Dados	Snapshot OSM, cenários de 12/30/60 entregas, sete dias e três benchmarks
Experimentos	278 execuções tabuladas, três configurações e dez sementes finais
Interpretação	gpt-6-luna pela Responses API, saída estruturada e orçamento acumulado
Documentação	Dois notebooks, gráficos, mapas, relatório e roteiro de apresentação
Validação	Casos conhecidos, adulterações, integração HTTP e aceite por evidências

A conclusão do projeto é a entrega local validada. A equipe realizará a gravação do vídeo, a publicação e a submissão. O roteiro prevê 14 minutos e 30 segundos, sem incluir essas ações no trabalho automatizado.

2 Modelo de dados e restrições

Cada cenário contém um depósito, entregas com identificadores únicos, carga, prioridade, atendimento e localização, além de uma frota com capacidade e autonomia. A ordem dos nós nas matrizes é depósito seguido pelas entregas. A localização não define a identidade de um pedido: duas entregas no mesmo endereço permanecem distintas.

Regra	Conferência
Visitas	Todos os pedidos exatamente uma vez, sem IDs desconhecidos
Capacidade	Soma da carga inicial de cada rota dentro do limite do veículo
Autonomia	Distância completa, incluindo retorno ao depósito
Horários	Deslocamento dirigido e atendimento das paradas anteriores
Matrizes	Dimensão correta, diagonal zero, valores finitos e pares alcançáveis coerentes
Publicação	Rota viável recertificada antes da consulta e da interpretação

Os veículos saem em paralelo no horário inicial comum, sem reabastecimento. A carga diminui ao longo das entregas. Não há coletas, janelas de atendimento, restrições térmicas nem incompatibilidade entre tipos de carga. Autonomia significa distância máxima; não representa um modelo energético.

Objetivo entre soluções viáveis

J = distância total em quilômetros + α × soma dos minutos de chegada ponderados pela prioridade. Usamos α = 0,05 km/min. O tempo de atendimento de uma parada afeta a chegada das seguintes, mas não a chegada à própria parada.

Prioridade	Peso inicial
Regular	1
Urgente	3
Crítica	10

A avaliação compara primeiro erros estruturais, depois violações de capacidade e autonomia, e só então J. Um percurso inválido não vence por ser mais curto. Nos benchmarks CVRPLIB e no TSP FIAP, usamos exclusivamente a distância original, sem misturar unidades ou prioridades médicas.

3 Evolução da base FIAP

Preservamos a base FIAP no commit d236a2ae6a08fefdb8ee9f1ca3f8201223a92da3. Os arquivos originais e seus hashes permitem conferir a origem. O arquivo LICENSE declara CC0 1.0, embora o README mencione MIT; registramos essa divergência sem substituir a licença presente no commit.

Aspecto	Base original	Projeto atual
Problema	TSP com um circuito	Múltiplos veículos e restrições
Genes	Coordenadas	IDs exclusivos e separadores
Seleção	Roleta	Torneio de três
Crossover	OX com o mesmo pai no laço	OX com pais distintos quando possível
Mutação	Troca entre vizinhos	Troca ou inversão
Elitismo	Um indivíduo	Dois indivíduos
Verificação	Comprimento do ciclo	Certificação independente de visitas e limites
Aplicação	Interface Pygame	Pacote, CLI, API e mapas

O crossover original distingue valores de coordenadas, mas não identifica pedidos. Seu teste de pertencimento pode perder a multiplicidade de entregas no mesmo endereço. O novo OX atua sobre genes únicos e conserva todos os pedidos e separadores.

A representação permite rotas vazias quando um veículo não é usado. A reparação determinística procura realocações e trocas que reduzam violações. Ela preserva as visitas, mas não garante encontrar uma solução para todo problema viável. O código separa avaliação da busca e verificação da solução publicada.

A reprodução da referência remove apenas a dependência gráfica e mantém seus operadores, probabilidade de mutação 0,50, um elite e crossover com o mesmo pai. Essa comparação é restrita ao TSP de 15 pontos compatível com a fonte.

4 Dados e preparação geográfica

Obtivemos uma malha de ruas direcionadas do OpenStreetMap com OSMnx 2.1.1. O recorte vai de -46,69 a -46,61 de longitude e de -23,59 a -23,52 de latitude. Retivemos a maior componente fortemente conexa, com 7.029 nós e 14.036 arestas, permitindo ida e retorno entre os pontos escolhidos.

Cada par usa o caminho de menor tempo estimado na malha. Distância, duração e polilinha são calculadas sobre as mesmas arestas. A velocidade deriva do campo maxspeed quando disponível, de imputação por tipo de rua e de fallback de 30 km/h. Sentidos das ruas são considerados; trânsito atual e restrições de conversão não são modelados.

Conjunto	Escalas e frota	Sementes
Desenvolvimento	12/2, 30/3 e 60/5 entregas/veículos	617+n
Avaliação final	12/2, 30/3 e 60/5	2026+n
Semana simulada	Sete dias com 12 entregas e dois veículos	5000 a 5006
Variações	Prioridade, capacidade e autonomia	Semente 42 da busca
CVRPLIB	A-n32-k5, A-n54-k7 e A-n80-k10	Instâncias públicas originais

Cargas são inteiros de 2 a 10 kg; prioridades são sorteadas com proporções de 55%, 30% e 15%. O atendimento utiliza 180, 300 ou 420 segundos. A capacidade nominal é o teto de 1,35 vezes a carga total dividida pela frota, com autonomia de 50 km. As datas de 5 a 11 de outubro são simulações, sem alegação de operações ocorridas.

As instâncias CVRPLIB preservam os arquivos VRP e SOL, capacidade, frota e arredondamento EUC_2D floor(d+0,5). O endereço original apresentou certificado TLS expirado; a obtenção usou o espelho mantido pelo autor, com commit e hashes registrados e validação TLS ativa. As soluções publicadas foram conferidas independentemente.

A malha, ruas, matrizes e geometrias são incluídas localmente. A atribuição © OpenStreetMap contributors e a licença ODbL 1.0 são conservadas. Uma nova obtenção pode refletir alterações da fonte; os resultados desta entrega usam o snapshot salvo.

5 Experimentos e orçamento de busca

Comparamos três configurações do genético. Crossover, torneio e elitismo permanecem fixos. A seleção da configuração de uso considera apenas a média da razão J do GA/J do guloso nos três cenários de desenvolvimento, com três sementes por configuração. A escolha é registrada antes da avaliação final.

Configuração	População	Mutação	Crossover
pop80_mut10	80	0,10	0,90
pop160_mut20	160	0,20	0,90
pop240_mut30	240	0,30	0,90

A configuração selecionada foi pop80_mut10. Cada configuração usa dez sementes nos sete problemas finais: três cenários médicos, três instâncias CVRPLIB e o TSP FIAP. As sementes são 42, 73, 101, 127, 151, 181, 211, 241, 271 e 307. As execuções adicionais cobrem sensibilidade, restrições e a semana simulada.

O teto de 20.000 inclui todas as chamadas de fitness da busca, inclusive inicialização e reparação. Há também um limite de 20.000 tentativas da população, para encerrar alta repetição de indivíduos, e de 120 segundos. Custos de inserção de rotas parciais são contados separadamente. A certificação final fica fora do orçamento de otimização.

Uma primeira implementação contava apenas as tentativas da população. Ao revisar o orçamento, identificamos que as chamadas da reparação não estavam incluídas. Invalidamos o uso desses resultados na comparação final e repetimos os experimentos com a contagem corrigida. A entrega utiliza exclusivamente as execuções com contagem completa.

OR-Tools usa cinco segundos, restrições de capacidade e autonomia e objetivo equivalente, convertido em inteiros com precisão documentada. O guloso escolhe a melhor entre três construções determinísticas. Os orçamentos não são equivalentes; tempo de execução e limite de busca são apresentados separadamente. Os tempos foram medidos em CPU local com outras atividades em paralelo e não constituem um benchmark isolado de hardware.

Cada resultado registra semente, parâmetros, versão dos dados, hash da implementação, duração, fitness, tentativas, diversidade e condição de término. Checkpoints permitem retomar sem repetir uma execução já conferida.

6 Resultados nos cenários médicos

Pedidos	Método	J médio	Desvio de J	km médios	Viáveis
12	Guloso	60,857	0,000	40,974	1/1
12	OR-Tools	60,079	0,000	40,459	1/1
12	GA selecionado	60,079	0,000	40,459	10/10
30	Guloso	181,929	0,000	71,572	1/1
30	OR-Tools	175,840	0,000	69,406	1/1
30	GA selecionado	181,244	0,688	70,900	10/10
60	Guloso	363,389	0,000	118,318	1/1
60	OR-Tools	339,971	0,000	110,967	1/1
60	GA selecionado	363,389	0,000	118,318	10/10

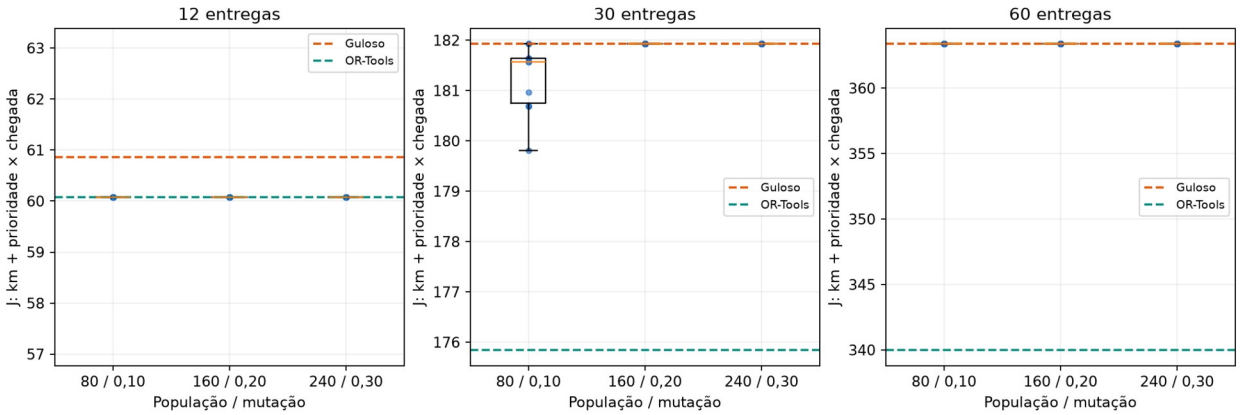


Figura 1 Distribuição de J por configuração e comparação com guloso e OR-Tools.

Com 12 entregas, as configurações alcançam o mesmo J de OR-Tools nas sementes finais. Com 30 entregas, o GA selecionado apresenta pequenas melhorias sobre a construção gulosa, mas mantém custo superior ao OR-Tools. No cenário de 60 entregas, a busca preserva a solução inicial e não demonstra ganho sobre o guloso.

A igualdade entre sementes nos problemas maiores não comprova robustez da evolução: pode resultar do orçamento consumido pela reparação. A distância e J devem ser lidos separadamente, pois J também considera chegada ponderada. Todos os resultados viáveis foram certificados quanto às restrições.

7 Convergência e uso do orçamento

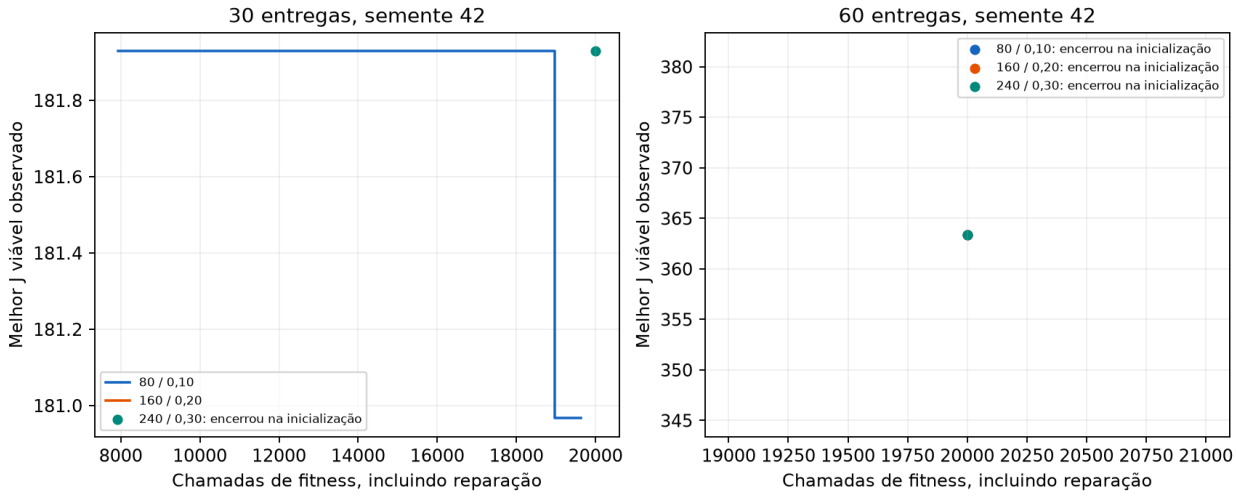


Figura 2 Melhor J viável observado e interrupções antes de completar gerações.

Nos cenários maiores, a reparação avalia numerosas inserções e trocas. Ao contabilizar esse custo dentro das 20 mil chamadas, parte das execuções termina durante a inicialização. Um ponto isolado no gráfico indica esse término e não deve ser apresentado como convergência de um processo evolutivo completo.

Condição de término	Execuções GA tabuladas
evaluation_budget	190
candidate_attempt_budget	60

O limite de tentativas encerra a busca quando a população repete candidatos, mesmo que a quantidade de chamadas novas de fitness seja menor que 20 mil. Esse encerramento evita interpretar cache como processamento adicional. A melhor solução viável já avaliada é conservada quando o orçamento termina em qualquer etapa.

A conclusão é que a reparação implementada funciona como mecanismo de preservação de restrições, mas é cara para este orçamento. Uma reparação incremental, candidatos de inserção mais seletivos e construção inicial com melhor diversidade são propostas de melhoria. Elas exigiriam nova avaliação; não atribuímos ganhos a versões ainda não testadas.

8 Resultados nos benchmarks públicos

Instância	Método	Distância média	Gap médio %	Viáveis
A-n32-k5	Guloso	1117,0	42,47	1/1
A-n32-k5	OR-Tools	784,0	0,00	1/1
A-n32-k5	GA selecionado	1100,5	40,37	10/10
A-n54-k7	Guloso	1544,0	32,31	1/1
A-n54-k7	OR-Tools	1241,0	6,34	1/1
A-n54-k7	GA selecionado	1540,0	31,96	10/10
A-n80-k10	Guloso	2398,0	36,02	1/1
A-n80-k10	OR-Tools	1810,0	2,67	1/1
A-n80-k10	GA selecionado	2398,0	36,02	10/10

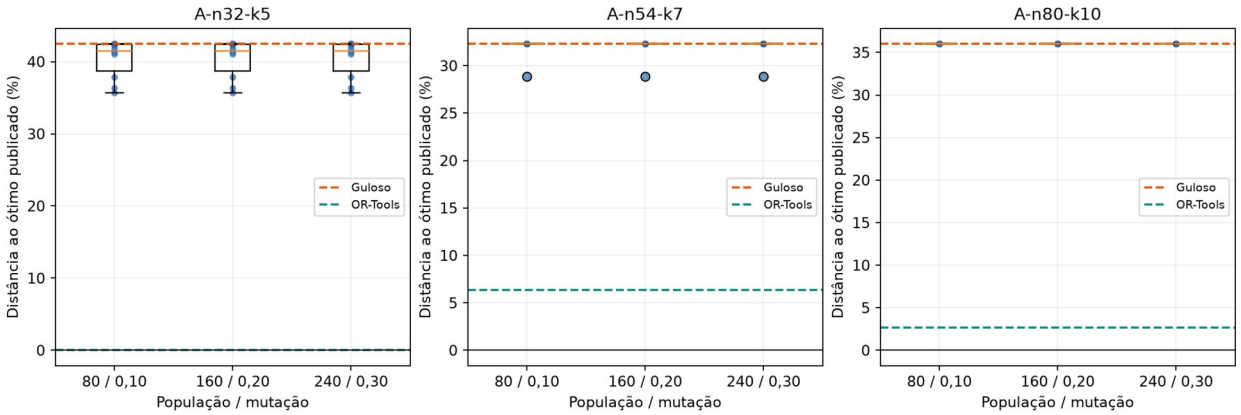


Figura 3 Distância relativa aos custos publicados 784, 1167 e 1763.

OR-Tools alcançou o custo publicado na instância A-n32-k5 e ficou mais próximo da referência nas demais. O genético permaneceu acima desses custos, com pequenas melhorias sobre o guloso em alguns casos. A-n80-k10 não apresentou ganho do GA sobre a construção inicial neste orçamento.

Os gaps utilizam unidades originais do benchmark. Não são percentuais de quilômetros nem estimativas de atraso hospitalar. As soluções publicadas e todas as soluções experimentais viáveis respeitam a capacidade e o atendimento de cada cliente exatamente uma vez.

9 Comparação com o TSP FIAP

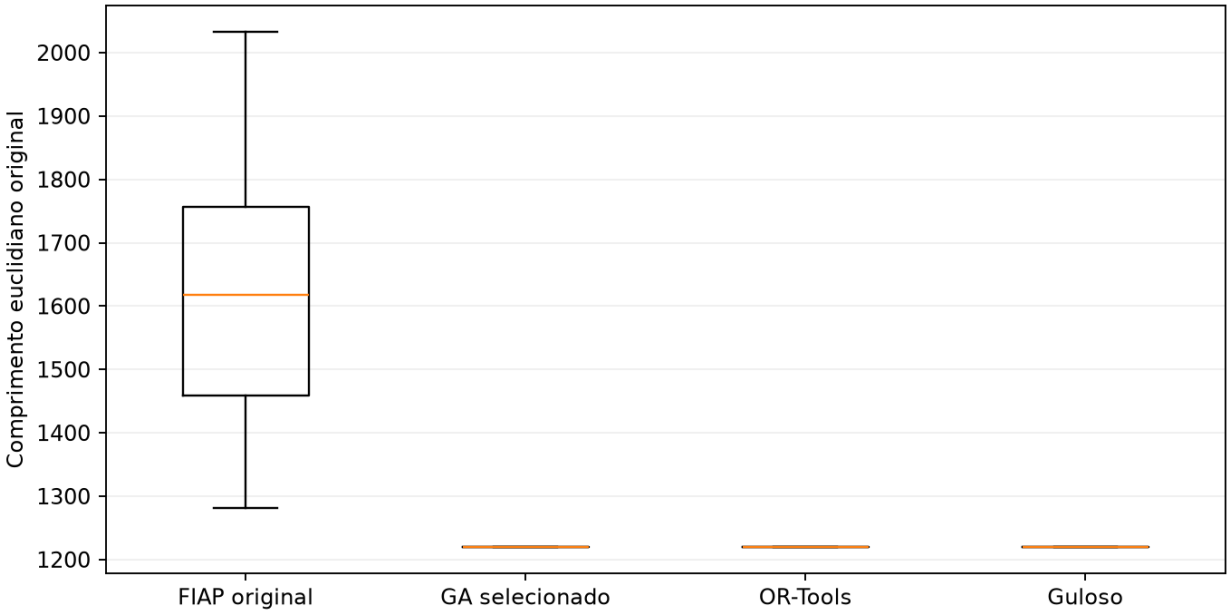


Figura 4 Comprimento dos circuitos no TSP original de 15 pontos.

A referência FIAP apresentou média de 1619,286 unidades euclidianas. A configuração selecionada apresentou 1219,225. O guloso e OR-Tools alcançaram o mesmo valor observado pelo novo GA nesse cenário.

Esse resultado mostra vantagem da implementação completa sobre a reprodução da referência, mas não isola o efeito da correção do crossover. Mudaram também a inicialização, a seleção, a mutação, o elitismo e o uso de construção gulosa. Como o novo GA coincide com a solução inicial nesse TSP, não atribuímos a redução exclusivamente à evolução genética.

O comparador mantém a chamada OX com o mesmo pai e a mutação por troca de vizinhos. A nova versão opera com IDs exclusivos e separadores, mas, nesta comparação, usa somente um veículo e a distância euclidiana original. O experimento não mistura as restrições do problema médico com o TSP da fonte.

10 Sensibilidade e restrições mais rígidas

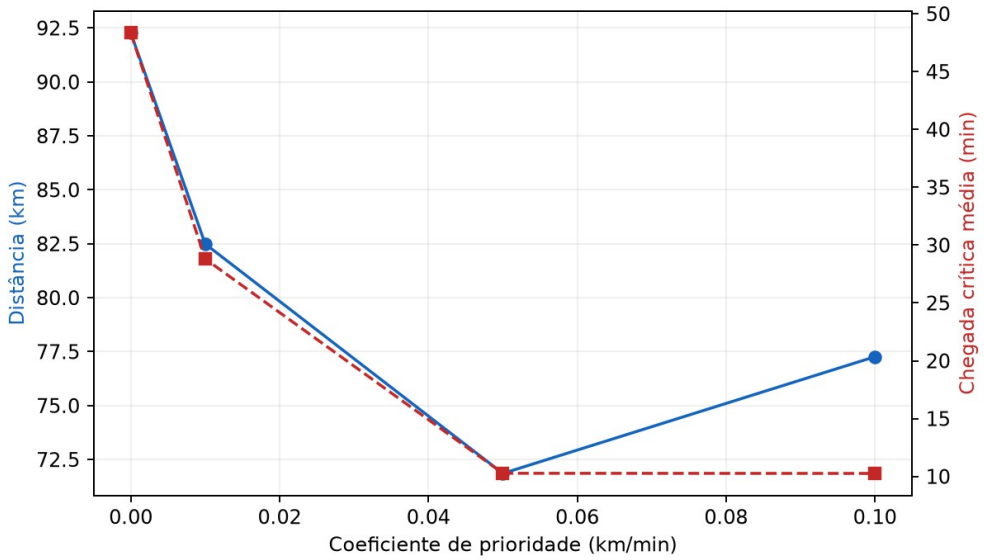


Figura 5 Distância e chegada crítica ao variar o coeficiente de prioridade.

A sensibilidade considera coeficientes 0, 0,01, 0,05 e 0,10 em um cenário de 30 entregas e uma semente. A distância e a chegada crítica podem variar sem uma relação monotônica, pois a busca é heurística e tem orçamento finito. Esse gráfico explora a premissa e não estabelece pesos clínicos nem causalidade.

Variação	Método	J	Viáveis
Capacidade 82%	greedy	185,841	1/1
Capacidade 82%	ortools	176,021	1/1
Capacidade 82%	genetic	185,841	1/1
Autonomia 25 km	greedy	181,646	1/1
Autonomia 25 km	ortools	—	0/1
Autonomia 25 km	genetic	181,362	1/1

Na variação de autonomia, OR-Tools não encontrou solução com a estratégia configurada, embora o guloso e o GA tenham encontrado rotas viáveis. Essa falha de busca não prova impossibilidade do problema. O resultado foi mantido, com diagnóstico e sem publicar uma rota inválida.

11 Rotas sobre as ruas de São Paulo

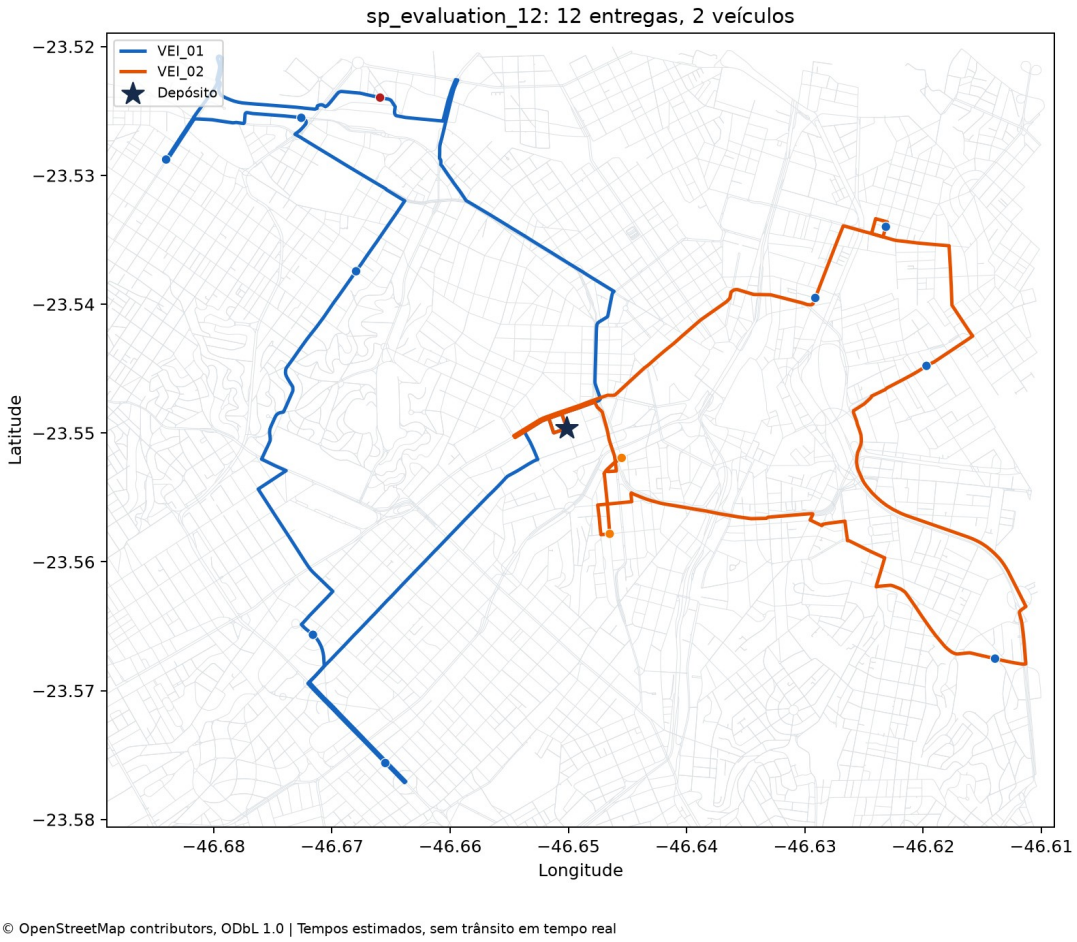


Figura 6 Rotas certificadas do cenário de 12 entregas, semente 42.

As linhas acompanham as ruas e retornam ao depósito marcado por uma estrela. As cores dos marcadores representam prioridades e as linhas distinguem os veículos. A geometria é a mesma utilizada nas matrizes. O HTML correspondente permite zoom e seleção de veículos sem carregar mapas ou JavaScript externos.

O traçado demonstra coerência geográfica e respeito ao sentido das vias, mas não valida condições operacionais do dia. Trânsito, bloqueios e restrições de conversão exigiriam um modelo adicional.

12 Frota e chegada das entregas críticas

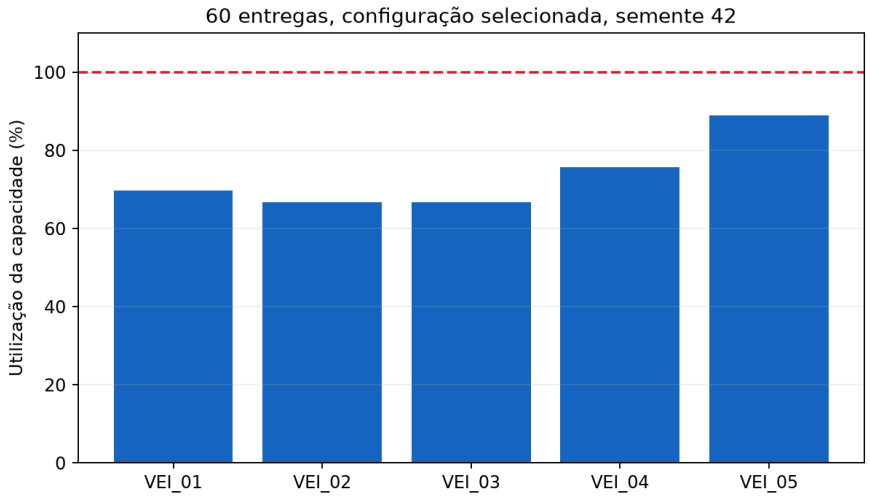


Figura 7 Carga inicial de cada veículo como percentual de sua capacidade.

A carga inicial inclui todos os pedidos da rota. Os veículos não recebem novas cargas durante o percurso e não realizam coletas. A capacidade é conferida independentemente; utilizar menos de 100% não representa desperdício sem considerar localização, autonomia e prioridades.

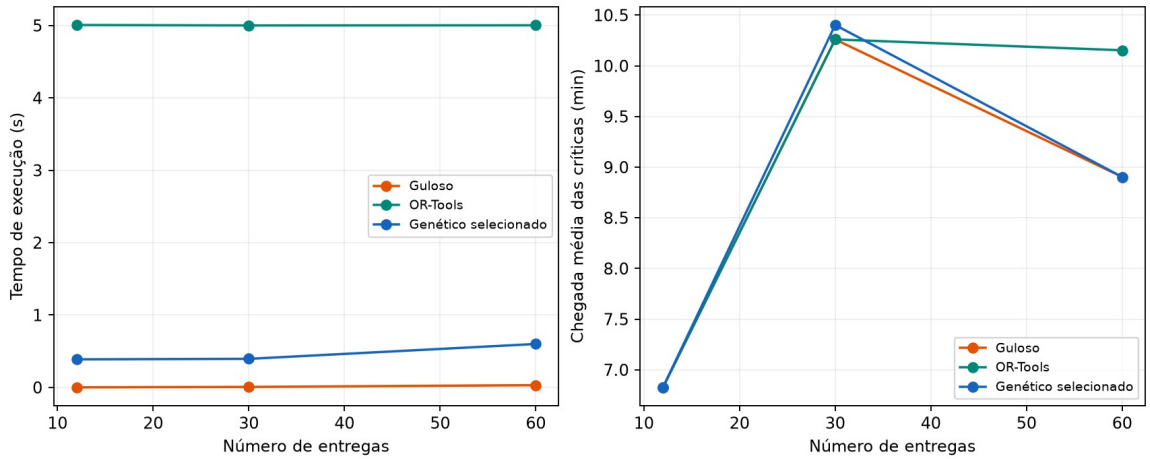


Figura 8 Tempo de execução e chegada média das entregas críticas.

As chegadas usam minutos após a saída de cada veículo. O tempo de execução é a duração computacional da busca. São medidas distintas. OR-Tools tem cinco segundos; o GA tem limites de fitness e tentativas. A diferença de orçamento impede interpretar estas curvas como uma comparação de eficiência com esforço idêntico.

13 Integração com a LLM e controle factual

Usamos gpt-6-luna pela Responses API com saída estruturada e raciocínio configurado como none. O modelo recebe fatos extraídos de soluções certificadas, a pergunta e as opções autorizadas de organização. Ele seleciona referências, agrupa seções e identifica a sequência de entregas de cada veículo.

Responsabilidade	Implementação
Métricas e horários	Calculados e certificados em Python
Instruções	Veículo, solução e ordem integral de IDs conferidos
Relatórios	Fatos diários e agregações semanais previamente calculados
Perguntas	Seleção dos fatos pertinentes ou resposta de dados insuficientes
Sugestões	Ações condicionais de um vocabulário explícito, sem inventar nova otimização
Origem	API real, cache com origem original ou teste identificado

Os valores e as frases factuais são renderizados pelo Python. O esquema limita as referências aos fatos existentes e só permite instruções no tipo correspondente. A LLM seleciona e organiza esses fatos, sem escrever livremente novos números ou afirmações clínicas. Essa escolha limita a redação e permite conferência objetiva; a utilidade ainda depende da seleção pertinente ao pedido.

O primeiro prompt apresenta o contrato de seleção de fatos. O segundo explicita o papel de intérprete, o tratamento de conteúdo não confiável, os dados que não podem ser inferidos e a preservação de rotas. Os mesmos 30 casos são usados nos dois prompts.

Perguntas sobre pacientes, temperatura, estoque, trânsito atual, combustível, custo financeiro e prazos clínicos não têm suporte nos dados. A resposta deve reconhecer essa ausência. Uma sugestão de alteração operacional requer nova simulação e certificação; sua menção não comprova melhoria.

14 Avaliação dos prompts e orçamento da LLM

O conjunto fixo contém instruções, relatórios diários e semanais, perguntas respondíveis, oito pedidos de dados ausentes e duas tentativas de indução. Avaliamos status adequado, fatos necessários e preservação da ordem. Toda resposta aceita deve manter consistência factual; a taxa útil nos casos respondíveis deve ser de pelo menos 90%.

Prompt	Casos	Aceitas	Utilidade	Clareza
v1	30	27	90,9%	4,93
v2	30	30	100,0%	4,83

O resultado do aceite da LLM foi aprovado, com prompt selecionado v2. As respostas rejeitadas permanecem nos registros e reduzem a taxa de utilidade. A origem e o consumo das chamadas são preservados.

A rubrica de clareza considera duplicação, excesso de seções e volume de fatos numa pergunta direta. Avalia uma apresentação controlada; não mede empatia, compreensão clínica ou qualidade de prosa livre. Esse limite deve acompanhar a interpretação das notas.

A rodada inicial falhou: utilidade de 81,8% e 68,2%, com seis dos oito pedidos sem dados corretos em cada prompt. A segunda rodada ainda confundiu uma pergunta sobre recuperação clínica com premissas logísticas. Preservamos ambas e seus custos. Revisamos listas vazias, índices, indução e ausência de informação clínica, além de limitar referências aos fatos existentes. O contrato final é comum aos dois prompts. Como a revisão usou estes casos, as taxas não estimam generalização para perguntas novas.

Antes de cada chamada, a API conta os tokens de entrada e o ledger SQLite reserva o custo máximo, dentro de US$ 1 acumulado. A reserva usa limite conservador de US$ 0,125/milhão de entrada e US$ 0,50/milhão de saída. O uso retornado é reconciliado, e timeouts sem consumo conhecido mantêm a reserva. Não há retries automáticos do SDK.

Compromisso conservador acumulado: US$ 0,085726, em 180 chamadas contabilizadas. O teto inclui falhas, repetições e saídas incompletas.

A chave fica fora do Git e dos notebooks. Respostas de cache são recertificadas contra os fatos atuais e mantêm a origem original. O snapshot JSON do ledger permite reconstruir o banco local conservando o gasto do projeto.

15 Semana simulada

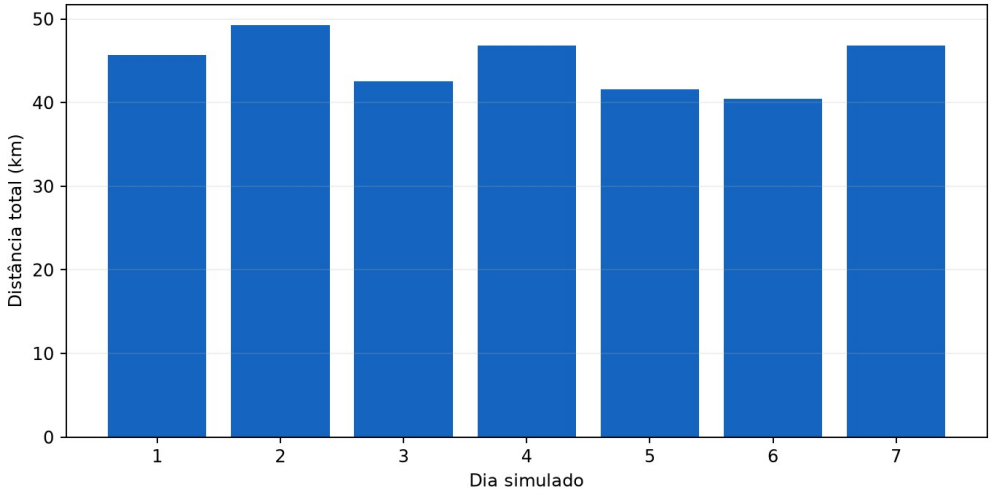


Figura 9 Distância diária dos sete cenários fictícios.

Dia simulado	Entregas	Distância km	Veículos
2026-10-05	12	45,652	2
2026-10-06	12	49,233	2
2026-10-07	12	42,574	2
2026-10-08	12	46,786	2
2026-10-09	12	41,601	2
2026-10-10	12	40,437	2
2026-10-11	12	46,805	2

O período contém 84 entregas e 313,088 km planejados. A soma dos veículos usados em cada dia representa veículos-dia; não é uma contagem de veículos físicos distintos.

A variação entre dias resulta das localizações, cargas e prioridades sorteadas. Não representa histórico de desempenho de hospitais. O relatório semanal interpreta os totais calculados e preserva as premissas de tempo e simulação.

16 Verificação e reprodução

O certificador independente recalcula visitas, carga, distância, autonomia, horários e métricas sem usar o fitness ou a reparação. O oráculo enumera permutações e divisões de rotas em casos pequenos. Os testes incluem limites exatos, assimetria, entregas no mesmo endereço, pedidos impossíveis, dados inválidos e adulterações de soluções.

O último conjunto registrado contém 53 casos de teste. O XML e o log preservam os resultados e os nomes dos grupos executados.

Na API, verificamos um processo Uvicorn com HTTP real: saúde, Swagger, otimização, consulta persistida e respostas a IDs inexistentes e solicitações inválidas. Os endpoints da LLM dependem de sua própria evidência real. Uma resposta de indisponibilidade não aprova a integração com o provedor.

A conferência geográfica reconstrói matrizes e geometrias a partir do snapshot salvo. Os mapas são abertos no navegador e as figuras estáticas são inspecionadas. Os dois notebooks executam em kernels novos. O relatório é convertido em páginas PNG para conferir tabelas, figuras, quebras de página e legibilidade.

Comando	Finalidade
tc2 experimentos	Executar ou retomar os experimentos com fingerprints
tc2 otimizar sp_evaluation_12 --mapa	Executar um cenário e gerar o mapa
tc2 api	Iniciar API local e Swagger
tc2 avaliar-llm	Executar ou retomar a avaliação dos dois prompts
python scripts/executar_notebooks.py	Executar os dois notebooks integralmente
tc2 validar --perfil entrega	Consolidar critérios como aprovado, falhou ou pendente

Os caminhos nos artefatos são relativos ao projeto. A instalação usa ambiente virtual e dependências fixadas após validação. Os arquivos de dados preservam origem, versão e licença. O aceite só é aprovado quando todas as evidências exigidas existem e concordam; pendências externas permanecem pendências.

17 Conclusão e próximos passos

A implementação estende o TSP da base FIAP para múltiplos veículos, prioridades, capacidade e autonomia, com dados geográficos e integração de linguagem fundamentada. A principal contribuição é um fluxo verificável: os algoritmos propõem rotas, o Python certifica e a camada de linguagem interpreta fatos autorizados.

Os experimentos demonstram viabilidade e melhor desempenho que a referência FIAP no TSP compatível, mas não sustentam superioridade geral do genético. Nos problemas maiores, a reparação consome o orçamento e limita a evolução; OR-Tools apresenta custos mais próximos das referências. A análise mantém esses resultados desfavoráveis e distingue falha de busca de prova de impossibilidade.

Como evolução, propomos reparação incremental, inicialização com diversidade viável e avaliação de limites maiores de busca. Essas alterações devem ser medidas novamente nos conjuntos separados. Também seriam necessários trânsito, restrições de conversão, janelas de atendimento e validação dos pesos com especialistas antes de considerar aplicação operacional.

A integração com LLM utiliza apresentação controlada para reduzir erros factuais. Uma futura versão com prosa livre exigiria avaliação semântica mais abrangente, além da conferência de identificadores e valores. A rubrica atual mede seleção e organização de fatos, sem avaliar competência clínica.

A equipe pode apresentar o problema, os operadores, os dados, as comparações, os mapas e a interpretação em até 14 minutos e 30 segundos. A gravação e a submissão serão realizadas pela equipe, a partir do roteiro e dos comandos incluídos.

18 Referências e localização dos artefatos

FIAP Base de algoritmo genético TSP
https://github.com/FIAP/genetic_algorithm_tsp

CVRPLIB Instâncias e soluções de referência
https://galgos.inf.puc-rio.br/cvrplib/en/instances

Espelho CVRPLIB mantido por Thibaut Vidal
https://github.com/vidalt/CVRPLIB

OSMnx Preparação e análise da rede viária
https://osmnx.readthedocs.io/en/stable/user-reference.html

OpenStreetMap Atribuição e licença
https://www.openstreetmap.org/copyright

OR-Tools Vehicle routing problem
https://developers.google.com/optimization/routing/vrp

Plotly Exportação de HTML interativo
https://plotly.com/python/interactive-html-export/

OpenAI Modelo gpt-6-luna
https://developers.openai.com/api/docs/models/gpt-6-luna

OpenAI Contagem de tokens
https://developers.openai.com/api/docs/guides/token-counting

OpenAI Saídas estruturadas na Responses API
https://developers.openai.com/api/docs/guides/structured-outputs?api-mode=responses

Fontes consultadas em outubro de 2026. O enunciado IADT Fase 2 e o relatório da fase 1 foram utilizados como referências acadêmicas. Não são incorporados como instruções de execução da aplicação.

Pasta	Conteúdo
src/rotas_medicas	Domínio, algoritmos, verificação, API, mapas e LLM
data	Cenários, matrizes e fontes preservadas
outputs/experiments	Soluções, tabelas e parâmetros
outputs/figures e maps	Gráficos, figuras e mapas HTML
outputs/validation	Evidências e relatório de aceite
notebooks e docs	Análises executáveis, arquitetura, plano e roteiro